

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №1

по дисциплине «Математическая статистика»

Тема: Гистограммы и плотности распределений

Выполнил: Медведьков Р.А.
Группа: 5030102/30201

Содержание

1	Постановка задачи	2
2	Теоретическая часть	2
2.1	Выбор числа интервалов	2
2.2	Распределения	2
3	Реализация	3
4	Результаты	3
4.1	Нормальное распределение $N(0, 1)$	3
4.2	Распределение Коши $C(0, 1)$	3
4.3	Распределение Лапласа $L(0, 1/\sqrt{2})$	4
4.4	Распределение Пуассона $P(10)$	4
4.5	Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$	4
5	Обсуждение	5
6	Выводы	5
7	Список литературы	5
8	Приложение	5

1 Постановка задачи

Цель работы — исследование влияния объёма выборки на вид гистограммы и её соответствие теоретическому распределению.

В рамках работы необходимо:

- Сгенерировать выборки объёмами $n = 10, 100, 1000$;
- Рассмотреть следующие распределения:
 1. Нормальное $N(0, 1)$;
 2. Коши $C(0, 1)$;
 3. Лапласа $L(0, 1/\sqrt{2})$;
 4. Пуассона $P(10)$;
 5. Равномерное $U(-\sqrt{3}, \sqrt{3})$;
- Построить гистограммы;
- Сравнить их с теоретическими плотностями;
- Сделать выводы.

2 Теоретическая часть

Гистограмма является одним из основных инструментов оценки плотности распределения случайной величины. Она строится путём разбиения выборки на интервалы и подсчёта количества значений в каждом интервале.

2.1 Выбор числа интервалов

Качество гистограммы напрямую зависит от числа бинов. В работе используются:

- правило $\sqrt{n}$ — для малых выборок;
- правило Фридмана–Диакониса:

$$h = 2 \cdot IQR \cdot n^{-1/3}$$

2.2 Распределения

Нормальное:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

Коши:

$$f(x) = \frac{1}{\pi(1+x^2)}$$

Лапласа:

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}$$

Пуассона:

$$P(k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Равномерное:

$$f(x) = \frac{1}{b-a}$$

3 Реализация

Для выполнения лабораторной работы использовался язык программирования Python.

Используемые библиотеки:


- numpy — генерация выборок;
- scipy.stats — вычисление теоретических плотностей и вероятностей;
- matplotlib — построение графиков.

Алгоритм работы программы включает несколько этапов. Сначала для каждого распределения и каждого объёма выборки генерируются случайные данные. Затем по полученным выборкам строятся гистограммы. После этого на каждый график накладывается соответствующая теоретическая плотность распределения, а для распределения Пуассона — функция вероятностей. В конце все изображения сохраняются в отдельные файлы для последующего включения в отчёт.

4 Результаты

В данном разделе приведены результаты моделирования для пяти распределений. Для каждого распределения построены три гистограммы, соответствующие выборкам объёма $n = 10$, $n = 100$ и $n = 1000$. На каждый график наложена теоретическая плотность распределения, а для распределения Пуассона — теоретическая функция вероятностей.


4.1 Нормальное распределение $N(0, 1)$



Гистограммы и теоретическая плотность для нормального распределения $N(0, 1)$ при $n = 10$, $n = 100$ и $n = 1000$.

Для нормального распределения уже при $n = 100$ становится заметной характерная симметричная форма. При $n = 1000$ гистограмма хорошо согласуется с теоретической кривой, а случайные отклонения становятся существенно меньше.


4.2 Распределение Коши $C(0, 1)$



Гистограммы и теоретическая плотность для распределения Коши $C(0, 1)$ при $n = 10$, $n = 100$ и $n = 1000$.

Для распределения Коши приближение к теоретической плотности происходит значительно медленнее. Это связано с тяжёлыми хвостами: отдельные большие по модулю значения заметно влияют на форму гистограммы даже при больших объёмах выборки.


4.3 Распределение Лапласа $L(0, 1/\sqrt{2})$



Гистограммы и теоретическая плотность для распределения Лапласа $L(0, 1/\sqrt{2})$ при $n = 10$, $n = 100$ и $n = 1000$.

Для распределения Лапласа хорошо выражен острый максимум вблизи нуля. При увеличении объёма выборки форма гистограммы становится более устойчивой и всё лучше воспроизводит теоретическую плотность.


4.4 Распределение Пуассона $P(10)$



Гистограммы и теоретическая функция вероятностей для распределения Пуассона $P(10)$ при $n = 10$, $n = 100$ и $n = 1000$.

Так как распределение Пуассона является дискретным, сравнение проводится с теоретической функцией вероятностей. При малом объёме выборки наблюдаются значительные случайные колебания частот, однако при $n = 1000$ эмпирические значения уже хорошо повторяют теоретические.

4.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$



Гистограммы и теоретическая плотность для равномерного распределения $U(-\sqrt{3}, \sqrt{3})$ при $n = 10$, $n = 100$ и $n = 1000$.

Для равномерного распределения по мере роста объёма выборки гистограмма приобретает всё более прямоугольную форму. Уже при $n = 100$ видно хорошее согласование с теоретическим видом распределения, а при $n = 1000$ границы интервала становятся особенно отчётливыми.

5 Обсуждение

По полученным результатам можно сделать вывод, что увеличение объёма выборки приводит к улучшению качества приближения эмпирической гистограммы к теоретическому распределению. При малых значениях n влияние случайных факторов особенно велико, поэтому форма гистограммы может заметно отличаться от ожидаемой.

Наиболее быстро к теоретическому виду приближаются нормальное, лапласовское и равномерное распределения. Для распределения Коши характерна более медленная сходимость, так как редкие, но очень большие по модулю значения существенно влияют на визуальную картину. Для распределения Пуассона необходимо отдельно учитывать дискретную природу случайной величины.

6 Выводы

- При увеличении объёма выборки гистограмма становится более устойчивой и лучше приближает теоретическое распределение.
- Для распределений с лёгкими хвостами сходимость наблюдается быстрее.
- Для распределения Коши наличие тяжёлых хвостов приводит к заметному влиянию выбросов.
- Для дискретных распределений необходимо использовать сравнение с функцией вероятностей, а не с плотностью.

7 Список литературы

- Боровков А. А. Математическая статистика.
- Документация NumPy.
- Документация SciPy.
- Документация Matplotlib.

8 Приложение

Ссылка на репозиторий с исходным кодом:

<https://github.com/Jujunlor/matstat-course/tree/lab-1>