

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №2

по дисциплине «Математическая статистика»

Тема: Характеристики положения и рассеяния

Выполнил: Медведьков Р.А.
Группа: 5030102/30201

Содержание

1	Постановка задачи	2
2	Теоретическая часть	2
2.1	Характеристики положения	2
2.2	Квартили и полусумма квартилей	3
2.3	Оценка характеристик методом Монте-Карло	3
2.4	Робастность оценок	4
3	Реализация	4
4	Результаты	4
4.1	Нормальное распределение $N(0, 1)$	5
4.2	Распределение Коши $C(0, 1)$	5
4.3	Распределение Лапласа $L(0, 1/\sqrt{2})$	5
4.4	Распределение Пуассона $P(10)$	6
4.5	Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$	6
5	Обсуждение	7
6	Выводы	7
7	Список литературы	8
8	Приложение	8

1 Постановка задачи

Цель лабораторной работы состоит в исследовании характеристик положения выборки и анализе их поведения при различных объёмах выборки и различных типах распределений.

В рамках работы требуется для распределений

$$N(0, 1), \quad C(0, 1), \quad L(0, 1/\sqrt{2}), \quad P(10), \quad U(-\sqrt{3}, \sqrt{3})$$

генерировать выборки объёма $n = 10$, $n = 100$, $n = 1000$ и для каждой выборки вычислить следующие статистики:

- выборочное среднее $\bar{x}$;
- медиану med ;
- полусумму экстремальных элементов

$$z_R = \frac{x_{\min} + x_{\max}}{2};$$

- полусумму квартилей

$$z_Q = \frac{Q_1 + Q_3}{2};$$

- усечённое среднее z_{tr} , вычисляемое после удаления 10% наименьших и 10% наибольших наблюдений.

Для оценки поведения этих характеристик эксперимент повторяется 1000 раз. По полученным значениям каждой статистики вычисляются оценки математического ожидания и дисперсии:

$$E(z) \approx \bar{z}, \quad D(z) \approx \overline{z^2} - (\bar{z})^2.$$

Необходимо представить результаты в табличной форме и сделать выводы о том, как объём выборки и природа распределения влияют на точность и устойчивость оценок положения.

2 Теоретическая часть

2.1 Характеристики положения

В математической статистике характеристики положения используются для описания центральной тенденции распределения. Различные оценки центра обладают разной чувствительностью к выбросам, асимметрии и тяжёлым хвостам распределения.

Выборочное среднее

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

является естественной оценкой математического ожидания. Для распределений с конечной дисперсией оно обладает хорошими асимптотическими свойствами. Однако при наличии выбросов или тяжёлых хвостов эта оценка может становиться нестабильной.

Медиана — это значение, делящее упорядоченную выборку на две равные части. В отличие от среднего арифметического, медиана значительно менее чувствительна к редким большим выбросам и поэтому считается робастной оценкой положения.

Полусумма экстремальных значений

$$z_R = \frac{x_{\min} + x_{\max}}{2}$$

использует только два наблюдения — минимальное и максимальное. По этой причине данная характеристика очень чувствительна к выбросам и часто имеет большой разброс.

Полусумма квартилей

$$z_Q = \frac{Q_1 + Q_3}{2}$$

опирается на центральную часть выборки и является более устойчивой характеристикой центра, чем среднее или полусумма экстремумов.

Усечённое среднее получается после удаления определённой доли крайних значений. В данной работе отбрасывается по 10% наблюдений с каждого конца упорядоченной выборки. Эта оценка сочетает свойства среднего арифметического и робастных характеристик: при лёгких хвостах она близка по эффективности к среднему, а при наличии выбросов ведёт себя заметно устойчивее.

2.2 Квартили и полусумма квартилей

Квартили делят упорядоченную выборку на четыре части. Первый квартиль Q_1 соответствует уровню 25%, третий квартиль Q_3 — уровню 75%.

В данной работе для вычисления квартилей используется стандартный алгоритм библиотеки NumPy, основанный на линейной интерполяции. После нахождения квартилей вычисляется статистика

$$z_Q = \frac{Q_1 + Q_3}{2}.$$

Так как эта оценка использует центральную половину данных, она значительно менее чувствительна к аномальным значениям по сравнению с $\bar{x}$ и z_R .

2.3 Оценка характеристик методом Монте-Карло

Пусть для некоторой статистики z выполнено R независимых повторов эксперимента, в результате чего получены значения

$$z^{(1)}, z^{(2)}, \dots, z^{(R)}.$$

Тогда оценка математического ожидания определяется как

$$\bar{z} = \frac{1}{R} \sum_{r=1}^R z^{(r)},$$

а оценка второго момента —

$$\overline{z^2} = \frac{1}{R} \sum_{r=1}^R (z^{(r)})^2.$$

Оценка дисперсии вычисляется по формуле

$$D(z) \approx \overline{z^2} - (\bar{z})^2.$$

В работе используется $R = 1000$ повторов, что позволяет получить достаточно устойчивые численные оценки для сравнения различных статистик.

2.4 Робастность оценок

Под робастностью понимают устойчивость статистики к отклонениям от модели, прежде всего к наличию выбросов. Если отдельные наблюдения могут принимать очень большие по модулю значения, некоторые оценки центра теряют смысл или становятся крайне нестабильными.

Наиболее наглядно это проявляется для распределения Коши. У него отсутствует конечное математическое ожидание, поэтому выборочное среднее может принимать очень большие значения даже при большом объёме выборки. В то же время медиана, полусумма квартилей и усечённое среднее продолжают давать разумные результаты.

3 Реализация

Для выполнения лабораторной работы использовался язык программирования Python.

Используемые библиотеки:

- `numpy` — генерация выборок и численные вычисления;
- `scipy.stats` — вычисление усечённого среднего;
- `csv` — сохранение результатов в табличный файл.

Алгоритм программы состоит из следующих этапов:

1. Для каждого распределения и каждого объёма выборки $n = 10$, $n = 100$, $n = 1000$ выполняется 1000 повторов эксперимента.
2. На каждом повторе генерируется выборка заданного объёма.
3. Для полученной выборки вычисляются пять характеристик положения: $\bar{x}$, med , z_R , z_Q , z_{tr} .
4. После завершения 1000 повторов для каждой статистики вычисляются значения $E(z)$, $D(z)$ и $\sqrt{D(z)}$.
5. Результаты сохраняются в CSV-файл и затем переносятся в таблицы отчёта.

В программе используются следующие генераторы случайных величин:

- нормальное распределение: `normal(0, 1)`;
- распределение Коши: `standard_cauchy()`;
- распределение Лапласа: `laplace(0, 1/√2)`;
- распределение Пуассона: `poisson(10)`;
- равномерное распределение: `uniform(-√3, √3)`.

Усечённое среднее вычисляется после удаления 10% минимальных и 10% максимальных элементов. Такой подход уменьшает влияние крайних значений, сохраняя информацию о центральной части выборки.

4 Результаты

В данном разделе приведены таблицы со значениями $E(z)$ и $\sqrt{D(z)}$ для каждой статистики и каждого объёма выборки. Все значения округлены до трёх знаков после запятой.

4.1 Нормальное распределение $N(0, 1)$

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	-0.010	0.316	-0.004	0.101	0.001	0.030
Медиана	-0.011	0.367	-0.007	0.124	0.001	0.038
z_R	-0.006	0.441	0.003	0.312	-0.004	0.255
z_Q	-0.012	0.339	-0.004	0.114	0.002	0.033
Усечённое среднее	-0.011	0.322	-0.005	0.105	0.001	0.031

Таблица 1: Характеристики положения для нормального распределения $N(0, 1)$.

Для нормального распределения все статистики имеют математические ожидания, близкие к нулю, а при росте объёма выборки их разброс закономерно уменьшается. Наименьшие значения $\sqrt{D(z)}$ наблюдаются у выборочного среднего, полусуммы квартилей и усечённого среднего. Медиана также демонстрирует хорошую устойчивость, но её разброс при малых выборках немного больше. Полусумма экстремальных элементов z_R оказывается наименее точной оценкой центра, поскольку зависит только от двух крайних наблюдений.

4.2 Распределение Коши $C(0, 1)$

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	-0.194	29.551	-2.273	125.381	-0.731	33.380
Медиана	-0.002	0.590	-0.001	0.156	0.000	0.052
z_R	-0.855	146.971	-113.706	6267.203	-349.715	16509.559
z_Q	0.029	0.897	-0.004	0.222	0.002	0.073
Усечённое среднее	-0.029	1.490	-0.004	0.225	0.001	0.073

Таблица 2: Характеристики положения для распределения Коши $C(0, 1)$.

Для распределения Коши особенно ярко видно различие между робастными и неробастными оценками. Выборочное среднее и полусумма экстремумов имеют огромный разброс, причём он не уменьшается устойчиво с ростом n . Это связано с тяжёлыми хвостами распределения и отсутствием конечного математического ожидания. Медиана, полусумма квартилей и усечённое среднее, напротив, остаются близкими к нулю и демонстрируют значительно меньшие значения $\sqrt{D(z)}$, поэтому именно они оказываются практически пригодными характеристиками центра.

4.3 Распределение Лапласа $L(0, 1/\sqrt{2})$

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	0.000	0.316	0.002	0.100	0.000	0.031
Медиана	0.003	0.270	0.002	0.076	0.000	0.022
z_R	-0.009	0.643	-0.010	0.631	0.016	0.644
z_Q	0.000	0.300	0.000	0.099	0.000	0.032
Усечённое среднее	0.002	0.285	0.001	0.087	0.000	0.027

Таблица 3: Характеристики положения для распределения Лапласа $L(0, 1/\sqrt{2})$.

Для распределения Лапласа все оценки центра также стремятся к нулю. Медиана и усечённое среднее показывают немного меньший разброс, чем обычное среднее, что связано с более острым пиком распределения в нуле и большей чувствительностью среднего к хвостам. Полусумма экстремумов снова оказывается заметно хуже остальных характеристик: её разброс остаётся большим даже при $n = 1000$, поскольку крайние значения у распределения Лапласа могут быть достаточно удалёнными от центра.

4.4 Распределение Пуассона $P(10)$

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	10.047	1.011	9.995	0.322	9.999	0.099
Медиана	9.897	1.191	9.827	0.470	9.998	0.045
z_R	10.340	1.384	10.934	0.995	11.626	0.818
z_Q	9.974	1.086	9.919	0.382	9.995	0.050
Усечённое среднее	9.973	1.036	9.902	0.333	9.903	0.101

Таблица 4: Характеристики положения для распределения Пуассона $P(10)$.

Для распределения Пуассона центр находится вблизи 10, и большинство оценок действительно стремится к этому значению. Выборочное среднее демонстрирует наиболее естественное поведение: его математическое ожидание практически совпадает с теоретическим, а разброс убывает при увеличении n . Медиана и полусумма квартилей также хорошо описывают центр распределения. При этом полусумма экстремумов оказывается систематически завышенной, поскольку максимум выборки растёт с увеличением объёма, а минимум ограничен снизу. Усечённое среднее немного меньше 10, что объясняется правосторонней асимметрией распределения и удалением части больших значений.

4.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

Статистика	$n = 10$		$n = 100$		$n = 1000$	
	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$	$E(z)$	$\sqrt{D(z)}$
Среднее	0.010	0.318	0.001	0.099	0.000	0.031
Медиана	0.011	0.480	0.001	0.169	-0.001	0.054
z_R	0.006	0.217	0.000	0.024	0.000	0.002
z_Q	0.017	0.375	0.001	0.120	0.000	0.039
Усечённое среднее	0.011	0.363	0.001	0.117	-0.001	0.037

Таблица 5: Характеристики положения для равномерного распределения $U(-\sqrt{3}, \sqrt{3})$.

Для равномерного распределения оценки центра также стремятся к нулю, однако здесь особенно интересна статистика z_R . В отличие от предыдущих распределений, минимум и максимум выборки при росте n быстро приближаются к границам интервала, поэтому полусумма экстремальных значений оказывается очень точной оценкой центра. Это хорошо видно по резкому уменьшению $\sqrt{D(z)}$ для z_R вплоть до почти нулевого значения при $n = 1000$. Остальные оценки также демонстрируют устойчивое поведение, но по эффективности в этом случае уступают z_R .

5 Обсуждение

Полученные результаты хорошо согласуются с теоретическими свойствами рассматриваемых статистик.

Для нормального, лапласовского и равномерного распределений почти все оценки положения ведут себя устойчиво и при увеличении объёма выборки стремятся к истинному центру распределения. При этом разброс характеристик уменьшается с ростом n , что особенно хорошо заметно для выборочного среднего, медианы, полусуммы квартилей и усечённого среднего.

Полусумма экстремальных элементов z_R в большинстве случаев обладает наибольшим разбросом. Это объясняется тем, что она зависит только от двух наблюдений — минимального и максимального, которые сами по себе являются нестабильными величинами. Для симметричных распределений с лёгкими хвостами эта статистика всё же стремится к центру, но делает это заметно медленнее остальных оценок. Исключением является равномерное распределение, для которого z_R оказывается особенно удачной характеристикой благодаря быстрому приближению крайних порядковых статистик к границам носителя распределения.

Наиболее интересные результаты наблюдаются для распределения Коши. У этого распределения отсутствует конечное математическое ожидание, поэтому выборочное среднее не стабилизируется даже при больших n . Большой разброс $\bar{x}$ и особенно огромный разброс z_R в этом случае не являются вычислительной ошибкой, а отражают свойства самого распределения. В то же время медиана, z_Q и усечённое среднее продолжают демонстрировать устойчивое поведение и остаются близкими к истинному центру, равному нулю.

Для распределения Пуассона наблюдается другая особенность. Так как распределение дискретно и несимметрично, некоторые оценки могут иметь небольшое систематическое смещение. Особенно это заметно для z_R , поскольку максимум выборки растёт с увеличением n , а минимум ограничен снизу. Из-за этого полусумма экстремумов оказывается завышенной. Усечённое среднее, наоборот, немного занижает центр, так как при усечении удаляется часть крупных значений из правого хвоста. Тем не менее среднее, медиана и полусумма квартилей хорошо описывают положение распределения.

Усечённое среднее во всех случаях демонстрирует хороший баланс между устойчивостью и эффективностью. Для симметричных распределений с лёгкими хвостами оно близко по поведению к обычному среднему, а для распределений с тяжёлыми хвостами оказывается существенно надёжнее.

6 Выводы

В ходе лабораторной работы были выполнены все поставленные задачи:

1. Сгенерированы выборки объёма 10, 100 и 1000 для пяти заданных распределений.
2. Для каждой выборки вычислены пять характеристик положения: $\bar{x}$, med , z_R , z_Q , z_{tr} .
3. С помощью 1000 повторов эксперимента получены оценки математического ожидания и дисперсии каждой статистики.
4. Проведено сравнение поведения различных характеристик положения при росте объёма выборки.

По результатам работы можно сделать следующие выводы:

- Для распределений с конечной дисперсией увеличение объёма выборки приводит к уменьшению разброса оценок.

- Выборочное среднее является эффективной оценкой центра для нормального, лопласовского, равномерного распределений и распределения Пуассона.
- Для распределения Коши среднее арифметическое и полусумма экстремумов оказываются крайне нестабильными и непригодными в качестве надёжных характеристик центра.
- Медиана, полусумма квартилей и усечённое среднее являются более робастными характеристиками положения и лучше переносят наличие выбросов и тяжёлых хвостов.
- Полусумма экстремальных значений в большинстве случаев уступает другим оценкам по устойчивости и точности, однако для равномерного распределения она показывает очень хорошие результаты.

Следовательно, в практических задачах обработки данных следует выбирать оценку положения с учётом предполагаемой структуры распределения и возможного наличия аномальных наблюдений.

7 Список литературы

1. Кобзарь А. И. Прикладная математическая статистика. — М.: Физматлит, 2006.
2. Боровков А. А. Математическая статистика. — М.: Наука, 1984.
3. Casella G., Berger R. Statistical Inference.
4. Документация NumPy.
5. Документация SciPy.

8 Приложение

Ссылка на репозиторий с исходным кодом:

<https://github.com/Jujunlor/matstat-course/tree/lab-2>