

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №3

по дисциплине «Математическая статистика»

Тема: Боксплот Тьюки и анализ выбросов

Выполнил: Медведьков Р.А.
Группа: 5030102/30201

Содержание

1	Постановка задачи	2
2	Теоретическая часть	2
2.1	Боксплот Тьюки и его элементы	2
2.2	Правило Тьюки для определения выбросов	2
2.3	Зависимость выбросов от распределения	3
2.4	Влияние объёма выборки	3
3	Реализация	3
4	Результаты	4
4.1	Боксплоты	4
4.2	Экспериментальная оценка доли выбросов	6
5	Обсуждение	6
5.1	Сравнение долей выбросов	6
5.2	Влияние объёма выборки	6
6	Выводы	7
7	Список литературы	7
8	Приложение	8

1 Постановка задачи

Целью лабораторной работы является изучение метода визуализации распределений с помощью боксплота Тьюки, а также исследование выбросов в выборках различного объёма.

Рассматриваются распределения:

$$N(0, 1), \quad C(0, 1), \quad L(0, 1/\sqrt{2}), \quad P(5), \quad U(-\sqrt{3}, \sqrt{3})$$

Требуется:

- построить боксплоты для $n = 20$ и $n = 100$;
- провести 1000 экспериментов;
- определить среднюю долю выбросов;
- проанализировать результаты.

2 Теоретическая часть

2.1 Боксплот Тьюки и его элементы

Боксплот (ящик с усами), предложенный Джоном Тьюки, является одним из основных инструментов описательной статистики, позволяющим визуально оценить распределение данных.

Основные элементы боксплота:

- медиана Q_2 — центральное значение выборки;
- первый квартиль Q_1 — значение, ниже которого находится 25% данных;
- третий квартиль Q_3 — значение, ниже которого находится 75% данных;
- межквартильный размах:

$$IQR = Q_3 - Q_1;$$

- «усы» — границы нормальных значений;
- выбросы — значения за пределами допустимого диапазона.

Боксплот позволяет одновременно оценить положение центра распределения, разброс данных и наличие аномальных наблюдений.

2.2 Правило Тьюки для определения выбросов

В основе метода лежит использование межквартильного размаха. Значения считаются выбросами, если они выходят за пределы интервала:

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR].$$

Коэффициент 1.5 выбран эмпирически и обеспечивает разумный баланс:

- при слишком малом коэффициенте слишком много точек будут считаться выбросами;
- при слишком большом — реальные выбросы могут не обнаруживаться.

Для симметричных распределений с лёгкими хвостами (например, нормального) правило Тьюки отсекает примерно 0.7% наблюдений.

2.3 Зависимость выбросов от распределения

Количество выбросов определяется формой распределения:

- для распределений с лёгкими хвостами (нормальное) выбросы редки;
- для распределений с тяжёлыми хвостами (Коши) выбросы возникают часто;
- для ограниченных распределений (равномерное) выбросы практически отсутствуют.

Таким образом, доля выбросов является характеристикой распределения и отражает его вероятностные свойства.

2.4 Влияние объёма выборки

При увеличении объёма выборки:

- оценки квартилей становятся более точными;
- границы выбросов стабилизируются;
- доля выбросов стремится к теоретическому значению.

При малых выборках возможны значительные отклонения из-за случайных флуктуаций.

3 Реализация

Использован Python.

Библиотеки:

- numpy;
- matplotlib;
- csv.

Алгоритм:

1. Генерация 1000 выборок;
2. Вычисление выбросов;
3. Усреднение;
4. Построение графиков.

4 Результаты

4.1 Боксплоты

На рисунках 1–5 представлены боксплоты Тьюки для выборок объёма $n = 20$ и $n = 100$ для каждого исследуемого распределения. Красными точками на графиках отмечены наблюдения, классифицируемые как выбросы по правилу Тьюки. Сопоставление боксплотов для двух различных объёмов выборки позволяет визуально оценить влияние числа наблюдений на устойчивость квартилей, длину усов и количество выделяемых аномальных значений.




Рис. 1: Боксплоты Тьюки для нормального распределения: слева $n = 20$, справа $n = 100$.

Для нормального распределения медиана располагается примерно в центре ящика, а усы имеют близкую длину по обе стороны, что соответствует симметрии распределения. Выбросы встречаются сравнительно редко. При увеличении объёма выборки структура боксплота становится более устойчивой, а оценка квартилей — более стабильной.




Рис. 2: Боксплоты Тьюки для распределения Коши: слева $n = 20$, справа $n = 100$.

Для распределения Коши характерно большое количество выбросов. Это связано с тяжёлыми хвостами: значения, сильно удалённые от центра, возникают здесь значительно чаще, чем в случае нормального распределения. Даже при увеличении объёма выборки доля выбросов остаётся высокой, а отдельные экстремальные наблюдения заметно влияют на вид графика.




Рис. 3: Боксплоты Тьюки для распределения Лапласа: слева $n = 20$, справа $n = 100$.

Распределение Лапласа также демонстрирует наличие выбросов, однако их количество заметно меньше, чем у распределения Коши. Это объясняется тем, что хвосты у распределения Лапласа тяжелее, чем у нормального, но легче, чем у Коши. Боксплот показывает симметричное распределение с более выраженным рассеянием значений вне центральной части выборки.




Рис. 4: Боксплоты Тьюки для распределения Пуассона: слева $n = 20$, справа $n = 100$.

Для распределения Пуассона боксплот отражает дискретную природу данных и некоторую правостороннюю асимметрию. При меньшем размере выборки возможны более заметные случайные отклонения формы ящика и положения медианы. При $n = 100$ картина становится более устойчивой, а доля выбросов уменьшается.




Рис. 5: Боксплоты Тьюки для равномерного распределения: слева $n = 20$, справа $n = 100$.

Для равномерного распределения выбросы практически отсутствуют. Это связано с тем, что все значения ограничены конечным интервалом, а границы Тьюки оказываются шире носителя распределения. Визуально боксплот имеет почти симметричный вид, а усы охватывают почти весь диапазон наблюдений.

4.2 Экспериментальная оценка доли выбросов

Для количественного анализа был проведён вычислительный эксперимент. Для каждого распределения и каждого объёма выборки генерировалось по 1000 выборок, после чего для каждой выборки вычислялась доля наблюдений, попадающих за пределы интервала

$$[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR].$$

Далее эти доли усреднялись. Полученные результаты приведены в таблице.

Распределение	n	Доля выбросов
Нормальное	20	0.0241
Нормальное	100	0.0098
Коши	20	0.1482
Коши	100	0.1552
Лапласа	20	0.0739
Лапласа	100	0.0666
Пуассона	20	0.0246
Пуассона	100	0.0145
Равномерное	20	0.0027
Равномерное	100	0.0000

Таблица 1: Исходные результаты эксперимента по средней доле выбросов.

5 Обсуждение

5.1 Сравнение долей выбросов

Из таблицы видно, что доля выбросов существенно зависит от типа распределения.

Для нормального распределения средняя доля выбросов при $n = 20$ составляет 2.41%, а при $n = 100$ — 0.98%. Теоретическое значение для нормального распределения равно примерно 0.7%. Полученные результаты демонстрируют, что при увеличении объёма выборки оценка стремится к теоретическому значению. При малых выборках наблюдается завышение, связанное с нестабильностью оценки квантилей.

Для распределения Коши доля выбросов значительно выше: около 15%. Это объясняется тяжёлыми хвостами распределения. Даже при больших объёмах выборки вероятность появления экстремальных значений остаётся высокой. Экспериментальные значения хорошо согласуются с теоретическим уровнем около 15.6%.

Распределение Лапласа даёт промежуточный результат: около 7%. Хвосты убывают медленнее, чем у нормального распределения, но быстрее, чем у Коши, что и определяет соответствующее количество выбросов.

Для распределения Пуассона доля выбросов составляет примерно 1.5–2.5%. Это связано с его дискретной природой и асимметрией. При увеличении объёма выборки наблюдается небольшое снижение доли выбросов, что объясняется стабилизацией оценок.

Равномерное распределение практически не даёт выбросов. Теоретически выбросов быть не должно, так как носитель ограничен, а границы Тьюки лежат далеко за пределами возможных значений. Небольшие отклонения при малых выборках связаны с случайными колебаниями.

5.2 Влияние объёма выборки

При увеличении объёма выборки наблюдается стабилизация оценок доли выбросов.

Для большинства распределений доля выбросов практически не зависит от n , что подтверждает её как характеристику распределения. Однако при малых выборках возможны значительные отклонения, связанные с неточной оценкой квартилей.

Особенно заметно влияние объёма выборки для нормального распределения, где при $n = 20$ доля выбросов существенно выше теоретической, а при $n = 100$ уже близка к ней.

Для распределения Коши доля выбросов остаётся стабильной даже при малых n , что связано с высокой вероятностью появления экстремальных значений.

6 Выводы

В ходе выполнения лабораторной работы были решены все поставленные задачи:

1. Сгенерированы выборки объёмом $n = 20$ и $n = 100$ для пяти распределений;
2. Построены боксплоты Тьюки, позволяющие визуально оценить структуру данных;
3. Проведён численный эксперимент с 1000 повторениями;
4. Вычислены средние доли выбросов.

На основании полученных результатов можно сделать следующие выводы:

- Доля выбросов определяется типом распределения и отражает его свойства;
- Для нормального распределения доля выбросов мала и стремится к теоретическому значению при увеличении объёма выборки;
- Распределение Коши характеризуется наибольшим количеством выбросов из-за тяжёлых хвостов;
- Распределение Лапласа занимает промежуточное положение;
- Для распределения Пуассона наблюдается умеренное количество выбросов;
- Равномерное распределение практически не содержит выбросов;
- Увеличение объёма выборки приводит к стабилизации оценок;
- Боксплот Тьюки является эффективным инструментом анализа, позволяющим выявлять выбросы и оценивать форму распределения.

Таким образом, метод Тьюки может использоваться как универсальный инструмент для первичного анализа данных и выявления аномальных наблюдений.

7 Список литературы

1. Боровков А. А. Математическая статистика. — М.: Наука, 1984.
2. Тьюки Дж. Анализ результатов наблюдений: разведочный анализ. — М.: Мир, 1981.
3. Документация библиотеки NumPy:
<https://numpy.org/doc/>
4. Документация библиотеки SciPy:
<https://docs.scipy.org/>
5. Документация библиотеки Matplotlib:
<https://matplotlib.org/stable/contents.html>

8 Приложение

<https://github.com/Jujunlor/matstat-course/tree/lab-3>