

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

по дисциплине «Математическая статистика»

Тема: Эмпирическая функция распределения и ядерные оценки плотности

Выполнил: Медведьков Р.А.
Группа: 5030102/30201

Содержание

1	Постановка задачи	2
2	Теоретическая часть	2
2.1	Эмпирическая функция распределения	2
2.2	Гистограмма	3
2.3	Ядерная оценка плотности	4
2.4	Ширина окна сглаживания	4
2.5	Исследуемые распределения	5
3	Реализация	5
4	Результаты	6
4.1	Нормальное распределение	6
4.2	Распределение Коши	7
4.3	Распределение Лапласа	7
4.4	Распределение Пуассона	8
4.5	Равномерное распределение	8
4.6	Влияние ширины окна	9
5	Обсуждение	9
6	Выводы	10
7	Список литературы	11
8	Приложение	11

1 Постановка задачи

Цель лабораторной работы состоит в исследовании непараметрических методов оценки функции распределения и плотности вероятности по выборочным данным.

В работе необходимо изучить два подхода:

- построение эмпирической функции распределения;
- построение ядерной оценки плотности.

Для исследования используются следующие распределения:

$$N(0, 1), \quad C(0, 1), \quad L(0, 1/\sqrt{2}), \quad P(10), \quad U(-\sqrt{3}, \sqrt{3}).$$

Для каждого распределения требуется:

1. Сгенерировать выборки объёма

$$n = 20, 60, 100.$$

2. Построить:

- эмпирическую функцию распределения;
- теоретическую функцию распределения;
- гистограмму;
- ядерную оценку плотности;
- теоретическую плотность распределения.

3. Сравнить поведение эмпирических оценок при разных объёмах выборки.

4. Исследовать влияние ширины окна сглаживания на качество ядерной оценки плотности.

Для непрерывных распределений графики строятся на интервале

$$[-4, 4],$$

для распределения Пуассона — на интервале

$$[6, 14].$$

2 Теоретическая часть

2.1 Эмпирическая функция распределения

Пусть имеется выборка

$$X_1, X_2, \dots, X_n$$

из распределения с функцией распределения

$$F(x).$$

Эмпирическая функция распределения определяется следующим образом:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x),$$

где

$$I(X_i \leq x)$$

— индикатор события.

Эмпирическая функция распределения показывает долю наблюдений, не превосходящих значение

$$x.$$

ЭФР является ступенчатой функцией:

- при каждом наблюдении происходит скачок;
- величина скачка равна

$$\frac{1}{n}.$$

Согласно теореме Гливенко–Кантелли,

$$\sup_x |\hat{F}_n(x) - F(x)| \rightarrow 0 \quad \text{при } n \rightarrow \infty.$$

Это означает, что при увеличении объёма выборки эмпирическая функция распределения равномерно приближается к истинной функции распределения.

2.2 Гистограмма

Гистограмма является одним из простейших способов оценки плотности распределения.

Вся область значений разбивается на интервалы — бины. Далее вычисляется количество наблюдений, попавших в каждый интервал.

Высота столбца пропорциональна плотности наблюдений внутри соответствующего интервала.

Для непрерывных распределений в работе используется правило Фридмана–Диакониса:

$$h = 2 \cdot IQR \cdot n^{-1/3},$$

где:

•

$$IQR = Q_3 - Q_1$$

— межквартильный размах;

•

$$n$$

— объём выборки.

Данное правило позволяет автоматически выбирать ширину бинов и хорошо работает для распределений различной формы.

2.3 Ядерная оценка плотности

Гистограмма является ступенчатой функцией, поэтому её форма зависит от выбора ширины интервалов.

Для получения более гладкой оценки плотности используется ядерное сглаживание.

Ядерная оценка плотности определяется формулой:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right),$$

где:

- $K(u)$
— ядро;
- h
— ширина окна сглаживания.

В данной работе используется гауссово ядро:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}.$$

Тогда вклад каждого наблюдения представляет собой маленькую нормальную кривую, а итоговая оценка получается суммированием всех таких вкладов.

2.4 Ширина окна сглаживания

Качество ядерной оценки сильно зависит от параметра h .

Если h слишком мало:

- график становится шумным;
- появляются ложные пики.

Если h слишком велико:

- происходит чрезмерное сглаживание;
- теряются особенности распределения.

В работе используется правило Сильвермана:

$$h = 1.06\sigma n^{-1/5},$$

где n — объём выборки.

Для распределения Коши используется робастная версия правила:

$$h = 0.9 \cdot \min\left(\sigma, \frac{IQR}{1.34}\right) n^{-1/5}.$$

Такой подход уменьшает влияние выбросов и тяжёлых хвостов.

2.5 Исследуемые распределения

Нормальное распределение

$$N(0, 1) : \quad f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

Распределение Коши

$$C(0, 1) : \quad f(x) = \frac{1}{\pi(1+x^2)}.$$

Распределение Лапласа

$$L(0, 1/\sqrt{2}) : \quad f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}.$$

Распределение Пуассона

$$P(10) : \quad P(X = k) = \frac{10^k e^{-10}}{k!}.$$

Равномерное распределение

$$U(-\sqrt{3}, \sqrt{3}) : \quad f(x) = \frac{1}{2\sqrt{3}}.$$

3 Реализация

Лабораторная работа выполнена на языке программирования Python.

Используемые библиотеки:

- `numpy` — генерация выборок и вычисления;
- `scipy.stats` — теоретические функции распределения и плотности;
- `matplotlib` — построение графиков.

Алгоритм программы:

1. Для каждого распределения генерируются выборки объёма

$$n = 20, 60, 100.$$

2. Для каждой выборки строится:

- гистограмма;
- ядерная оценка плотности;
- теоретическая плотность;
- эмпирическая функция распределения;
- теоретическая функция распределения.

3. Для непрерывных распределений применяется правило Фридмана–Диакониса.

4. Для распределения Пуассона используются бины шириной 1, центрированные по целым значениям.

5. Для распределения Коши вручную задаются диапазоны построения графиков, так как распределение имеет тяжёлые хвосты.
6. Ядерная оценка плотности реализована вручную через гауссово ядро.
7. Дополнительно исследуется влияние ширины окна:

$$0.5h, \quad h, \quad 2h.$$

Все графики автоматически сохраняются в папку `images`.

4 Результаты

4.1 Нормальное распределение




Рис. 1: Нормальное распределение: ЭФР и ядерная оценка плотности

4.2 Распределение Коши

Распределение Коши $C(0, 1)$




Рис. 2: Распределение Коши: ЭФР и ядерная оценка плотности

4.3 Распределение Лапласа

Распределение Лапласа $L(0, 1/\sqrt{2})$




Рис. 3: Распределение Лапласа: ЭФР и ядерная оценка плотности

4.4 Распределение Пуассона

Распределение Пуассона $P(10)$




Рис. 4: Распределение Пуассона: ЭФР и ядерная оценка плотности

4.5 Равномерное распределение

Распределение Равномерное $U(-\sqrt{3}, \sqrt{3})$




Рис. 5: Равномерное распределение: ЭФР и ядерная оценка плотности

4.6 Влияние ширины окна




Рис. 6: Влияние ширины окна на KDE для равномерного распределения




Рис. 7: Влияние ширины окна на KDE для распределения Лапласа

5 Обсуждение

Полученные результаты хорошо согласуются с теоретическими свойствами рассматриваемых распределений.

При увеличении объема выборки эмпирическая функция распределения всё точнее приближается к теоретической функции распределения. Особенно хорошо это видно для нормального и равномерного распределений.

Для распределения Коши при малых объёмах выборки наблюдаются сильные колебания, вызванные тяжёлыми хвостами. Однако даже в этом случае ЭФР постепенно приближается к теоретической функции распределения.

Ядерная оценка плотности даёт значительно более гладкую аппроксимацию по сравнению с гистограммой. При малых выборках возможны шумовые колебания, однако с ростом

$$n$$

качество оценки заметно улучшается.

Для распределения Лапласа хорошо заметен острый пик в нуле. Ядерная оценка постепенно приближается к теоретической плотности при увеличении объёма выборки.

Для равномерного распределения наблюдается характерный граничный эффект: ядерная оценка слегка выходит за пределы истинного носителя распределения. Это связано с тем, что гауссово ядро имеет бесконечный носитель.

Дополнительные графики показали влияние параметра

$$h.$$

При малом

$$h$$

оценка становится шумной и чувствительной к случайным флуктуациям. При большом

$$h$$

происходит чрезмерное сглаживание и потеря деталей.

Наиболее качественный результат достигается при использовании стандартного правила Сильвермана.

6 Выводы

В ходе выполнения лабораторной работы были выполнены все поставленные задачи:

1. Сгенерированы выборки объёма

$$20, 60, 100$$

для пяти распределений.

2. Построены:

- эмпирические функции распределения;
- теоретические функции распределения;
- гистограммы;
- ядерные оценки плотности;
- теоретические плотности.

3. Исследовано влияние объёма выборки на качество приближения.

4. Исследовано влияние ширины окна сглаживания на ядерную оценку плотности.

По результатам работы можно сделать следующие выводы:

- Эмпирическая функция распределения сходится к теоретической при увеличении объёма выборки.
- Ядерная оценка плотности позволяет получать более гладкие оценки по сравнению с гистограммой.
- Качество KDE сильно зависит от выбора параметра сглаживания.
- Для распределений с тяжёлыми хвостами необходимо использовать робастные методы выбора ширины окна.
- При больших выборках как ЭФР, так и KDE хорошо приближают истинные характеристики распределения.

7 Список литературы

1. Кобзарь А. И. Прикладная математическая статистика. — М.: Физматлит, 2006.
2. Боровков А. А. Математическая статистика. — М.: Наука, 1984.
3. Silverman B. Density Estimation for Statistics and Data Analysis. — Chapman and Hall, 1986.
4. Scott D. Multivariate Density Estimation. — Wiley, 2015.
5. Документация NumPy: <https://numpy.org/doc/>
6. Документация SciPy: <https://docs.scipy.org/doc/scipy/>
7. Документация Matplotlib: <https://matplotlib.org/stable/>

8 Приложение

Ссылка на репозиторий с исходным кодом:

<https://github.com/Jujun1or/matstat-course/tree/lab-4>